

# 特征自适应过滤的视网膜病变分级算法

梁礼明, 雷 坤, 詹 涛, 周珑颂

(江西理工大学电气工程与自动化学院, 江西 赣州 341000)

**摘 要:** 针对视网膜病变图像特征识别困难以及病变分级效率不高等问题, 提出一种特征自适应过滤的视网膜病变分级算法。首先, 算法利用 ResNet-50 网络构建的多尺度过滤分支(MFB)对视网膜病变图像进行逐级特征提取; 其次, 在不同尺度的过滤分支后级联自适应特征过滤块(AFFB)对视网膜病变图像进行特征增强与过滤; 然后, 使用特征互补融合模块(FCFM)对特征过滤后的多个局部增强特征进行信息互补, 并通过聚合局部增强特征的互补信息丰富视网膜病变图像的局部细节; 最后, 采用细粒度分类损失与焦点损失对具有不同局部特征信息的分级模型进行训练, 并在 IDRiD 数据集上进行实验。实验结果表明, 所提分级算法的准确率为 80.58%、加权 Kappa 系数为 88.70%、特异性为 94.20%、敏感性为 94.10%, 该算法能有效识别视网膜病变图像的细微病变区域并提高分级效率。

**关 键 词:** 视网膜病变; 病变分级; 自适应; 特征过滤; 多尺度特征

中图分类号: TP 391

DOI: 10.11996/JGj.2095-302X.2022050815

文献标识码: A

文章编号: 2095-302X(2022)05-0815-10

## Feature-adaptive filtering for retinopathy grading

LIANG Li-ming, LEI Kun, ZHAN Tao, ZHOU Long-song

(School of Electrical Engineering and Automation, Jiangxi University of Science and Technology, Ganzhou Jiangxi 341000, China)

**Abstract:** To address the difficulty in recognizing features of retinopathy images and the low efficiency of disease grading, a retinopathy grading algorithm based on feature adaptive filtering was proposed. Firstly, the algorithm used the multi-scale filtering branches (MFB) constructed by the ResNet-50 network to extract features of retinopathy images step by step. Secondly, cascade adaptive feature filter blocks (AFFB) was adopted after filtering branches of different scales to perform feature enhancement and filtering on retinopathy images. Then, the feature complementary fusion module (FCFM) was utilized to complement the multiple local enhancement features after feature filtering, and enrich the local details of the retinopathy image by aggregating the complementary information of the local enhancement features. Hierarchical models with different local feature information were trained and experiments were performed on the IDRiD dataset. The experimental results show that the accuracy of the proposed grading algorithm was 80.58%, the weighted kappa coefficient 88.70%, the specificity 94.20%, and the sensitivity 94.10%. The algorithm could effectively identify the subtle lesions in retinopathy images and improve the grading efficiency.

**Keywords:** retinopathy; lesion grading; adaption; feature filtering; multi-scale features

收稿日期: 2022-03-16; 定稿日期: 2022-06-15

Received: 16 March, 2022; Finalized: 15 June, 2022

基金项目: 国家自然科学基金项目(51365017, 6146301); 江西省自然科学基金(20192BAB205084); 江西省教育厅科学技术研究重点项目(GJJ170491)

Foundation items: National Natural Science Foundation of China (51365017, 6146301); Natural Science Foundation of Jiangxi Province (20192BAB205084); Key Project of Science and Technology Research of Jiangxi Provincial Department of Education (GJJ170491)

第一作者: 梁礼明(1967-), 男, 教授, 硕士。主要研究方向为医学图像处理、计算机视觉等。E-mail: 9119890012@jxust.edu.cn

First author: LIANG Li-ming (1967-), professor, master. His main research interests cover medical image processing, computer vision, etc. E-mail: 9119890012@jxust.edu.cn

糖尿病视网膜病变(diabetic retinopathy, DR)是糖尿病患者发病率极高的慢性并发症之一。根据国际糖尿病联盟发布的最新数据显示,目前在20~79岁的成人人群中糖尿病患者的人数已高达5.366亿<sup>[1]</sup>,形势严峻。由于患病人数快速增长以及相关医护资源紧缺,DR患者无法得到及时的诊断反馈,导致视网膜病变程度进一步加重,进而使DR患者的视力受到不可逆的损伤。因此,利用计算机辅助视网膜病变分级的智能算法研究,对预防糖尿病患者致盲有着非常重要的意义。

目前视网膜病变分级算法主要存在2个问题:一是不同病变时期的患者比例差异大,DR样本分布不均衡;二是微血管瘤、出血点以及硬性渗出物等细微病变特征与视网膜周围环境差异小,特征提取困难。针对DR样本分布不均衡的问题,SHI和ZHANG<sup>[2]</sup>提出多阶段迁移的方法对特征表示学习与分类过程进行独立训练,再使用类平衡损失函数对分级模型进行优化。该方法能有效缓解DR样本分布不平衡的影响,并提高分级性能。针对视网膜病变图像特征提取困难的问题,谢云霞等<sup>[3]</sup>先通过子图对视盘进行分割,再使用在线困难样本挖掘缓解在高分辨率眼底图像中模型难以获取细微病灶的问题。顾婷菲等<sup>[4]</sup>提出将细粒度分类方法<sup>[5]</sup>与多通道注意力选择机制相结合的方法用于视网膜病变分级预测,该方法通过排序损失对每层通道的信息量进行优化,使视网膜病变图像的局部特征区域具有更多的信息量,从而突出视网膜病变图像的细粒度特征信息。DU等<sup>[6]</sup>则使用渐进式训练策略与随机拼图生成器鼓励网络提取视网膜病变图像的细粒度特征并融合,进而获取视网膜病变图像的多粒度特征信息,从而提高分级性能。

虽然上述解决方法能有效解决视网膜病变分级存在的问题,但分级模型不能高效且准确定位视网膜的病变区域。于是本文提出一种仅通过网络逐级自适应过滤特征的算法用于视网膜病变区域的定位及分级预测。该算法通过多尺度过滤分支(multi-scale filtering branch, MFB)与自适应特征过滤块(adaptive feature filter block, AFFB)逐级挖掘视网膜病变图像的局部细节特征并对局部特征进行增强与抑制;接着使用特征互补融合模块(feature complementary fusion module, FCFM)对多个局部增强特征进行信息互补,并学习视网膜病变图像的细节特征;最后,利用细粒度分类损失<sup>[7]</sup>与焦点损失<sup>[8]</sup>所构建的组合损失对分级模型进行

训练,并在IDRiD数据集上进行实验,以期实现准确定位视网膜病变图像的病变区域以及对病变等级进行准确预测。

## 1 网络结构

### 1.1 多尺度过滤分支

由于微血管瘤与出血点等病变特征在眼底图像上分布不规律,且病变区域大小存在差异。如果仅使用ResNet-50网络<sup>[9]</sup>的最后一层输出进行特征过滤,模型无法充分学习视网膜病变图像的潜在细节特征。于是本文采用一种基于ResNet-50的MFB逐级处理视网膜病变图像,充分学习局部细节特征。该分支首先在Stage1阶段对输入的视网膜病变图像进行特征提取与下采样,获取视网膜病变图像的浅层特征;接着,通过AFFB对Stage1的局部特征进行增强与过滤,并利用Stage2对过滤后的图像特征进行特征提取与下采样;Stage3重复Stage2的操作。

MFB通过逐级改变特征图的尺寸进而缩小细粒度特征的区域范围,其中Stage1由ResNet-50网络的前三层Layer构成,输出特征维度为 $512 \times 28 \times 28$ ,用于提取视网膜病变图像的浅层特征信息;Stage2与Stage3分别为ResNet-50网络的Layer3与Layer4,输出特征维度分别为 $1024 \times 14 \times 14$ 与 $2048 \times 7 \times 7$ ,其主要用于学习特征过滤后的图像信息。MFB的结构如图1所示。

### 1.2 自适应特征过滤块

由于初期的DR图像中仅含有少量微血管瘤或出血点,特征识别困难。受SONG和WANG<sup>[10]</sup>的启发,本文采用AFFB对视网膜病变图像的不同尺度特征进行特征过滤,并结合MFB逐级挖掘视网膜病变图像的潜在局部细节。AFFB的结构如图2所示。

AFFB主要由SE<sup>[11]</sup>注意力机制、特征增强与特征抑制构成。AFFB首先通过全局平均池化(global average pooling, GAP)对特征通道进行全局压缩,再使用全连接层(fully connected layers, FC)训练通道权重并恢复通道维度。接着,利用归一化的权值矩阵与输入特征图逐点相乘,为特征图施加通道注意力。

通道注意力机制虽然能使模型关注信息量大的特征通道减少冗余特征信息,但其仅关注了特征通道信息,忽略了不同特征通道之间的关联性。为解决上述问题,本文算法按非通道维度 $W$ 重新

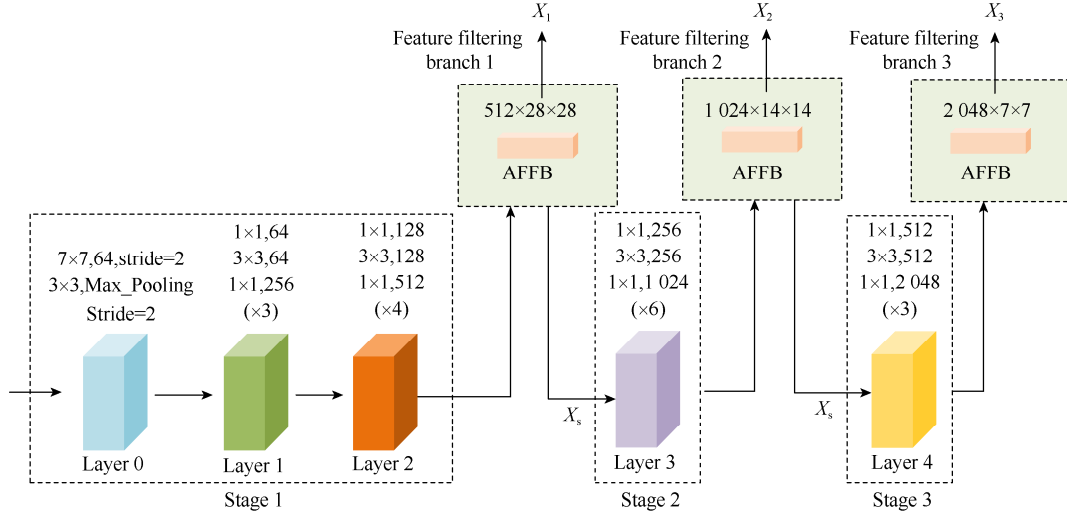


图1 多尺度过滤分支结构

Fig. 1 Multi-scale filtering branch structure

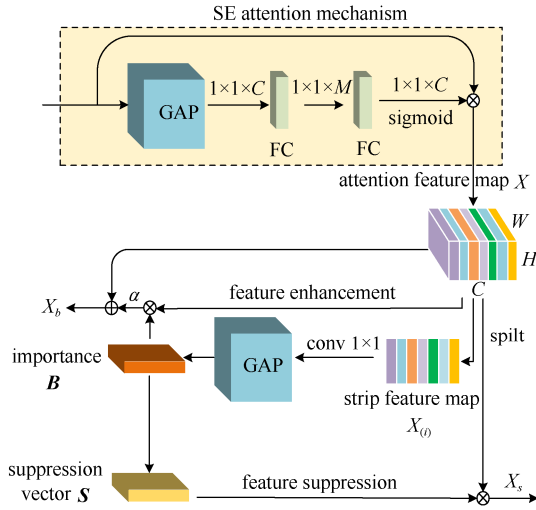


图2 自适应特征过滤块

Fig. 2 Structure diagram of adaptive feature filtering block

将特征图  $X \in R^{C \times W \times H}$  划分为  $k$  个条状特征图, 其中  $C$  为特征通道,  $W \times H$  为特征图的尺寸。通过对特征图的重新划分, 使条状特征图具有跨通道的特征信息, 再利用  $1 \times 1$  的卷积与  $\text{Relu}$  激活函数计算条状特征图的重要性  $A(i) \in R^{1 \times (W/k) \times H}$ , 即

$$A_{(i)} = \text{Relu}(\phi(X_{(i)})) \quad (1)$$

其中,  $X_{(i)}$  为第  $i$  个条状特征图。

随后, 利用 GAP 对  $A_{(i)}$  进行归一化并计算条状特征图的重要性因子  $b_i$ 。接着, 使用由  $k$  个重要性因子构成的重要性  $B$  与输入特征图进行加权融合, 进而对特征图施加跨通道的注意力, 使模型进行有效的特征学习并对局部特征进行增强, 即

$$b_i = \frac{\exp(\text{GAP}(A_{(i)}))}{\sum_{j \in [1, \dots, k]} \exp(\text{GAP}(A_{(j)}))} \quad (2)$$

$$X_b = X + \alpha \times (B \otimes X) \quad (3)$$

其中,  $\alpha$  为增强程度参数;  $\otimes$  为哈达玛积运算。

由于条状特征图的重要性权重越大, 其对应的特征信息量也越大, 为使下级特征提取网络能有效学习潜在的细粒度特征信息。本文通过特征抑制向量  $S$  对信息量大的特征进行特征抑制并过滤, 进而排除多余特征信息的干扰。其中特征抑制向量  $S$  取决于重要性因子  $b_i$ , 当  $b_i$  为  $B$  中的最大值时, 抑制因子  $S_i = 1 - \beta$ , 反之  $S_i = 1$ ,  $\beta$  表示抑制程度参数。特征抑制输出为

$$X_s = X \otimes S \quad (4)$$

### 1.3 特征互补融合模块

由于局部增强特征来自于 MFB, 具有多尺度信息, 所以局部增强特征之间的信息存在细微差异。因此, 本文算法采用 FCFM 对不同的局部增强特征进行信息互补, 通过聚合不同局部增强特征之间的互补信息对局部特征进行细化。FCFM 的结构如图 3 所示。

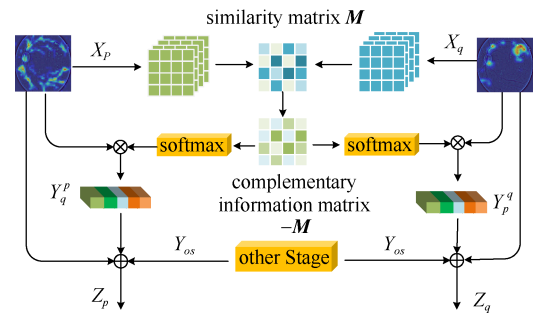


图3 特征互补融合块

Fig. 3 Feature complementary fusion block

FCFM 通过对局部增强特征间的相似度矩阵

进行反运算, 获取局部增强特征间的互补信息矩阵。随后, 利用互补信息矩阵对不同的局部增强特征进行信息互补融合。局部增强特征间的相似度矩阵为

$$\mathbf{M} = F(X_p, X_q) \quad (5)$$

其中,  $F(X, Y) = X^T Y$ ,  $X_p$  与  $X_q$  分别为不同尺度的局部增强特征;  $\mathbf{M}$  为局部增强特征间的相似度矩阵, 互补信息矩阵为  $-\mathbf{M}$ 。相似度矩阵中元素相似性越高, 局部增强特征间的互补信息越弱。

FCFM 通过 Softmax 层对互补信息矩阵进行归一化处理, 再将归一化后的互补信息矩阵  $A_q^p$  与局部增强特征进行相乘计算局部增强特征的互补信息  $Y_q^p$ , 即

$$A_q^p = \text{softmax}(-\mathbf{M}^T) \quad (6)$$

$$Y_q^p = X_p A_q^p \quad (7)$$

最后, 通过对不同局部增强特征的互补信息进行聚合, 从而获取局部特征输出为

$$Z_p = X_p + \gamma \times Y_{os} \quad (8)$$

其中,  $\gamma$  为融合参数, 取值为 0.5;  $Y_{os}$  为不同局部增强特征的互补信息。

#### 1.4 算法整体框架

特征自适应过滤的视网膜病变分级算法主要由 MFB, AFFB 和 FCFM 组成。该算法通过 MFB 与 AFFB 对视网膜病变图像进行逐级处理, 迫使网络模型持续挖掘视网膜病变图像的潜在细粒度特征。然后, 使用 FCFM 对局部增强特征进行信息互补, 并对局部增强特征的互补信息进行聚合。最后, 利用组合损失函数对分级模型进行训练。本文算法结构如图 4 所示。

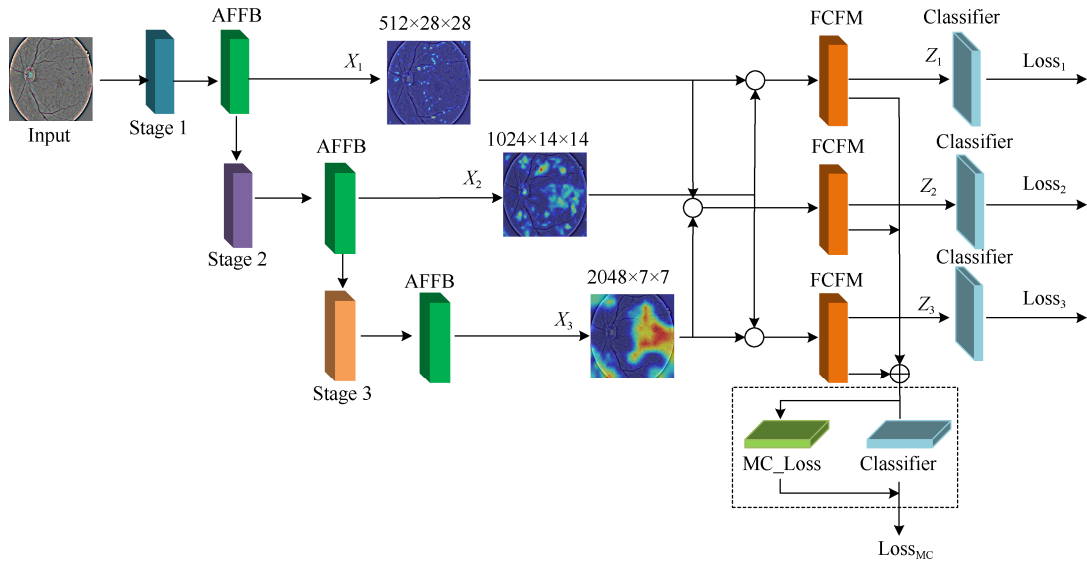


图 4 算法整体框架

Fig. 4 The overall framework of the algorithm

## 2 损失函数

该算法采用焦点(Focal)损失函数用于缓解视网膜病变图像样本不均衡对 DR 分级性能造成的影响, 并结合细粒度分类损失函数(mutual channel, MC)辅助 DR 分级模型充分学习视网膜病变图像中的细粒度特征。

Focal 损失函数主要通过加权误差调制指数来重塑交叉熵, 以减轻样本不均衡对模型的影响, 即

$$L_{\text{focal}} = -(1 - p^t)^r \ln(p^t) \quad (9)$$

其中,  $r$  为加权误差调制系数;  $p^t$  为标签预测概率。

MC 损失函数主用于辅助网络模型学习细粒度特征, 其由差异性分支( $L_{\text{dis}}$ )与多样性分支( $L_{\text{div}}$ )加权组成, 即

$$L_{\text{MC}} = L_{\text{dis}}(F) - \lambda \times L_{\text{div}}(F) \quad (10)$$

其中,  $F$  为特征图;  $\lambda$  为加权值, 取值为 10。

差异性分支由通道注意(channel-wise attention, CWA)、跨通道最大池化(cross-channel max pooling, CCMP)、GAP 和 Softmax 层构成。其中 CWA 用于捕获特征通道中的差异特征信息, CCMP 用于计算特征通道上的最大类别响应, 并对通道维度和空间维度进行降维。多样性分支由 Softmax 层、CCMP、Sum 和 Average 构成, 用于

计算不同类别特征通道之间的相似度, 及同时获取不同感兴趣区域。细粒度分类损失的结构如图5所示。




图5 细粒度分类损失结构图

Fig. 5 Fine-grained classification loss structure diagram

为提高 MFB 的特征提取能力, 本文算法的总损失中还引入了不同尺度过滤分支的分类损失, 即

$$L_{\text{loss}} = L_{\text{focal}} + \mu \times L_{\text{MC}} + \sum_{k=1}^3 L_{\text{cls}}^k \quad (11)$$

其中,  $\mu=0.5$ ;  $L_{\text{cls}}^k$  为不同尺度过滤分支的分类损失。

### 3 数据集及其预处理

#### 3.1 数据集来源

本文所使用的 IDRiD<sup>[12]</sup>数据集来源于2018年举行的 IEEE 生物医学图像国际研讨会, 其中包括516张眼底图像, 分辨率为4288×4288。该数据集根据国际临床DR严重程度标准, 将视网膜图像分为5类, 如图6所示。该数据集的样本分布见表1。

#### 3.2 数据预处理

由于视网膜病变图像的背景区域与病变区域对比不明显, 故先采用高斯平滑对视网膜病变图像进行预处理, 再与原图  $I_{(G)}$  进行加权融合, 进而提高视网膜病变图像的对比度, 并减少其他背景的干扰, 即

$$I_{(G)} = G_{\sigma} * I \quad (12)$$

$$G_{\sigma} = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (13)$$




图7 预处理对比结果((a)出血; (b)渗出物)

Fig. 7 Preprocessing comparison results ((a) Bleeding; (b) Exudate)

$$I_d = \omega I + \theta I_{(G)} + \varsigma \quad (14)$$

其中,  $\omega=4$ ,  $\theta=-4$ ,  $\varsigma=128$ ; \*为滤波操作;  $G_{\sigma}$  为二维高斯核;  $I_d$  为经过加权融合后的图像。预处理前后对比结果如图7所示。




图6 糖尿病视网膜病变类型((a)健康; (b)轻度非增殖性; (c)中度非增殖性; (d)重度非增殖性; (e)增殖性)

Fig. 6 Types of diabetic retinopathy ((a) Healthy; (b) Mild non-value added; (c) Moderate non-value added; (d) Severe non-value added; (e) Value-added)

表1 IDRiD 数据样本分布

Table 1 IDRiD data sample distribution

类别	病变等级	样本数量(个)
0	健康	168
1	轻度非增殖性	25
2	中度非增殖性	168
3	重度非增殖性	93
4	增殖性	62



此外, 本文针对 IDRiD 数据集的样本总量较小的问题, 采用了随机水平和垂直翻转、随机旋转与色彩抖动等数据增强方式对 IDRiD 数据集进行数据增强。

## 4 实验与讨论

本文所有的实验均在 Ubuntu16.04 操作系统进行, 基于 Pytorch1.5 框架建模, 仿真平台为 pycharm。计算机配置为 Nvidia GeForce GTX2070 GPU, Intel Core TM i7-6700H CPU, 16 G 内存。本文训练集包含 413 张视网膜病变图像, 测试集采用 103 张视网膜病变图, 训练批次为 5, 学习率为 0.002。

### 4.1 实验定性分析

#### 4.1.1 混淆矩阵

为分析本文算法与其他 DR 分级算法在 IDRiD 数据集上的预测性能, 图 8 给出了本文算法与其他算法的混淆矩阵。图 8(a)和(b)分别来源于文献[2]和文献[13]; 图 8(c)采用文献[10]的方法对 IDRiD 数据集进行训练后的预测结果, 其训练参

数与本文算法保持一致; 图 8(d)为本文算法的预测结果。

分析图 8 可知, 本文算法的混淆矩阵对角线样本分布更为集中, 且大多数误分样本均被分成相邻类, 而其他 3 种算法的混淆矩阵中部分样本被错分为其他类的情况严重。如果在实际临床中发生上述严重错分情况, 则会出现误诊, 导致患者错过最佳治疗时间。

通过对比本文算法与其他 DR 分级算法发现, 本文算法对早中期的视网膜病变预测效果更明显。其中对于视网膜病变等级为 1, 2 以及 3 的样本, 不仅正确预测结果增多, 还使得误分类数据样本越靠近主对角线位置区域。

由于 IDRiD 数据集测试样本偏少, 为防止本文算法在 IDRiD 数据集上的实验结果出现随机性。于是在 APTOS2019 数据集上进行了增强对比实验, 用于检验本文算法在 IDRiD 数据集上的预测结果。实验采用 ResNet-50 网络、文献[10]及本文 3 种模型均在 APTOS2019 数据集上进行训练并测试, 且前两种模型训练参数设置与本文算法保持一致。

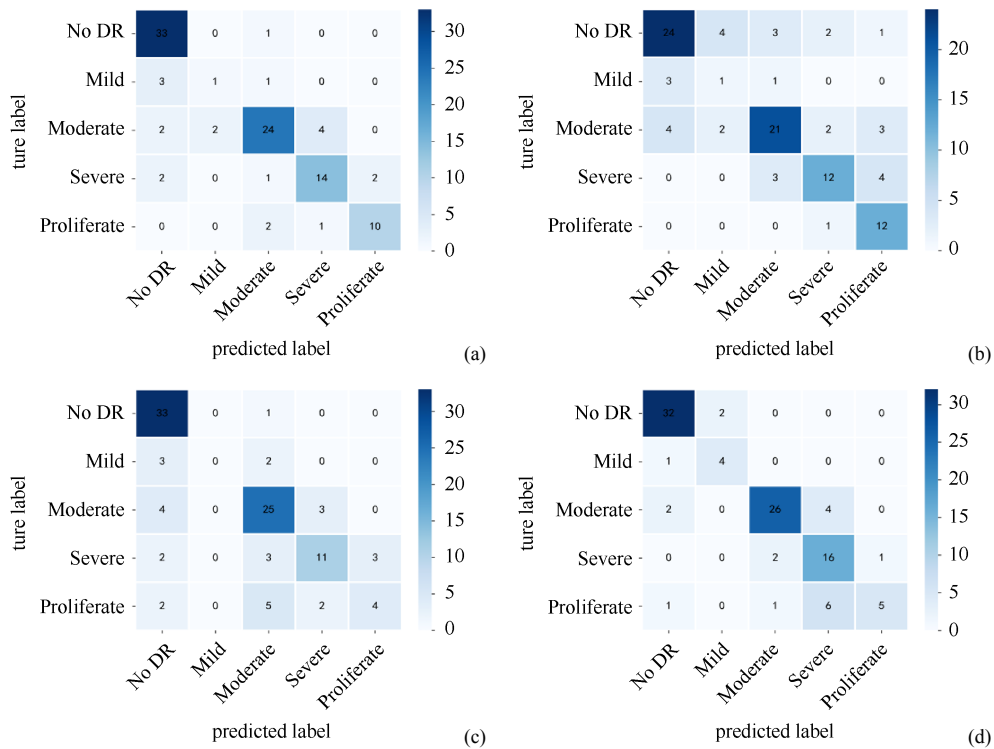


图 8 混淆矩阵((a)文献[2]; (b)文献[13]; (c)文献[10]; (d)本文算法)

Fig. 8 Confusion matrix ((a) Reference [2]; (b) Reference [13]; (c) Reference [10]; (d) Ours)

在 APTOS2019 数据集上的混淆矩阵对比结果如图 9 所示。其中, ResNet-50 网络与文献[10]的

预测样本分布较为散乱, 且对应样本误分为其他类别的情况较严重。此外, 其对角线上的样本总

量较少, 预测结果不理想。而本文算法的预测效果好于 ResNet-50 和文献[10]所对应的分级模型, 尤其对早中期视网膜病变图像的预测上, 具有明显的优势。

此外, 本文算法模型的混淆矩阵中误分类样本主要为相邻类, 而不是误分为其他类, 与在 IDRiD 数据集上的混淆矩阵可视化结果类似, 进而验证了本文算法在 IDRiD 数据集上的结果的可靠性。

#### 4.1.2 热力图

(1) 可视化局部增强特征。为分析 MFB 与 AFFB 逐级挖掘视网膜病变图像局部特征的过程。图 10 给出了 IDRiD 数据集中健康、轻度非增殖、

中度非增殖、重度非增殖与增殖性 5 种视网膜病变图像在不同 Stage 阶段的特征可视化结果。其中 Stage1 阶段的输出特征主要为视网膜病变图像的浅层特征, 该阶段靠近模型的输入端, 特征提取能力有限。

随着模型逐级加深, 视网膜病变图像的局部细节区域逐渐被关注。由轻度非增殖病变与重度非增殖病变的 Stage2 阶段所对应的特征可视化结果可看出, 模型的下一阶段特征输出更关注于视网膜病变图像的病变区域。不同 Stage 阶段的特征可视化结果证明 MFB 以及 AFFB 能充分挖掘视网膜病变图像的局部细节特征并丰富视网膜病变图像的细粒度特征。




图 9 增强对比实验((a) ResNet-50 网络; (b)文献[10]; (c)本文算法)

Fig. 9 Enhanced contrast experiment ((a) ResNet-50 network; (b) Reference [10]; (c) Ours)




图 10 可视化结果((a)健康; (b)轻度非增殖性; (c)中度非增殖性; (d)重度非增殖性; (e)增殖性)

Fig. 10 Visualizes the results((a) Healthy; (b) Mild non-value added; (c) Moderate non-value added; (d) Severe non-value added; (e) Value-added)

(2) 可视化预测结果。本文算法与 ResNet-50 网络模型在 IDRiD 数据集上的预测结果如图 11 所示。由于仅依靠 ResNet-50 网络模型提取视网膜病变图像特征的方式简单, 模型未能充分学习视网膜病变图像的细粒度特征信息, 进而导致模型的分级预测结果较差。而本文算法通过 MFB 与 AFFM 逐级挖掘视网膜病变图像的潜在细粒度特征, 能使模型高效地区分视网膜病变图像的病变区域, 提高分级模型的预测能力。

## 4.2 实验定量分析

### 4.2.1 评价指标

本文采用敏感性(sensitivity, Sen)、特异性(specificity, Spe)、准确率(accuracy, Acc)和加权 Kappa 系数(quadratic weighted kappa, QWK)对分级模型的性能进行评估, 即

$$\text{Sen} = \text{TP} / (\text{TP} + \text{FN}) \quad (15)$$

$$\text{Spe} = \text{TN} / (\text{TN} + \text{FP}) \quad (16)$$

$$\text{Acc} = (\text{TP} + \text{TN}) / (\text{TP} + \text{FP} + \text{FN} + \text{TN}) \quad (17)$$

其中, TP, FP, FN 和 TN 分别为真阳性、假阳性、假阴性、真阴性的样本数量。

加权 Kappa 系数为模型的一致性度量, 加权 Kappa 系数越大, 模型的一致性越高, 即

$$W_{i,j} = 1 - \frac{(i-j)^2}{(N-1)^2} \quad (18)$$

$$QWK = 1 - \frac{\sum_{i,j} W_{i,j} Q_{i,j}}{\sum_{i,j} W_{i,j} E_{i,j}} \quad (19)$$

其中,  $N$  为总类别数;  $W_{i,j}$  为第  $i$  类与  $j$  类的惩罚权重;  $Q_{i,j}$  为第  $i$  类判别为  $j$  类的数量;  $E_{i,j}$  为第  $i$  类的总数 $\times$ 第  $j$  类的总数/总数。




图 11 预测对比结果((a)原图; (b) ResNet-50; (c) Ours)

Fig. 11 Prediction comparison results ((a) Original image; (b) ResNet-50; (c) Ours)

### 4.2.2 与其他 DR 分级算法的对比

表 2 为本文算法与其他分级算法在 IDRiD 数据集上的实验对比, 其他算法的对比结果分别来源于对应参考文献。SIRAJUDEEN 和 EZHILARASI<sup>[14]</sup>采用的 LBP 算子虽然特征维度低, 计算速度快, 但亮度不均衡的视网膜病变图像会影响 LBP 算子学习视网膜病变图像的真实纹理特征。QIAO 等<sup>[15]</sup>则采用 Gabor 滤波器提取视网膜病变图像的纹理特征, 再结合支持向量机(support vector machine, SVM)分类器对视网膜病变图像进行分级预测。其中 Gabor 滤波器虽然对于图像的亮度和对比度变化以及图像姿态变化具有较强的鲁棒性, 但模型的

分级性能仍与本文算法有一定差距。BHARDWAJ 等<sup>[16]</sup>利用深度神经网络从眼底图像中提取特征, 并与机器学习方法进行结合, 虽然分级性能有很大进步但依然低于本文算法。WU 等<sup>[17]</sup>先利用粗网络判定眼底图像中是否存在病变, 然后再利用细网络对粗网络的预测结果进行分级预测, 虽然在一定程度上解决了正常样本与患病样本之间的分布不均衡, 但分级效果与本文算法仍有一定差距。

此外, 本文算法还对不同分级模型在 IDRiD 数据集上的一致性度量进行了对比, 结果由表 3 可知, 本文算法的模型一致性度量较好且优于现有 DR 分级算法。



表 2 不同 DR 分级算法对比结果  
Table 2 Comparison results of different DR classification algorithms

Methods	Backbone	Acc (%)	Sen (%)	Spe (%)
文献[14]	LBP+SVM	51.43	57.66	86.25
文献[15]	Gabor+SVM	<b>80.85</b>	76.75	78.76
文献[16]	ResNet-50	79.46	82.85	76.98
	GoogleNet	76.02	76.02	76.02
文献[17]	ResNet-18	56.19	64.21	87.39
Ours	ResNet-50	80.58	<b>94.20</b>	<b>94.10</b>

注: 加粗数据为最优值

表 3 一致性度量对比  
Table 3 Comparison of consistency metrics

Methods	Backbone	Kappa (%)
文献[2]	Efficientnet-b5	87.63
文献[5]	ResNet-50	86.94
文献[18]	VGG	86.31
文献[19]	VGG	85.11
文献[20]	ResNet-50	88.04
文献[21]	AlexNet+GoogleNet	85.73
文献[22]	CNN	84.00
Ours	ResNet-50	<b>88.70</b>

注: 加粗数据为最优值

4.2.3 消融实验

为验证本文算法模型的组合损失函数以及模型各组件的有效性, 在 IDRiD 数据集上对本文算法进行了消融实验与分析。消融实验主要分为组合损失函数和模型组件 2 部分。

(1) 组合损失函数。不同损失函数对 DR 分级性能的影响结果由表 4 可知, 使用 MC 损失函数辅助优化后的分级算法与仅采用交叉熵损失(cross entropy, CE)或 Focal 损失函数的算法相比, 前者的分级性能具有明显优势, 证明 MC 损失函数能有效辅助模型获取视网膜病变图像的细粒度特征信息。此外, 采用 Focal 损失函数的分级算法与采用 CE 损失函数的分级算法相比, 前者的加权 Kappa 比后者高出 2.25%, 由此说明 Focal 损失函数对提升视网膜病变分级模型的一致性度量有明显效果。

表 4 不同损失函数的对比结果(%)

Table 4 Comparison results of different loss function (%)

损失函数	Acc	Kappa	Sen	Spe
CE	78.86	86.52	90.35	92.34
Focal	79.03	88.77	89.96	90.65
CE+MC	79.84	86.67	90.23	92.53
Focal+MC	<b>80.58</b>	<b>88.70</b>	<b>94.20</b>	<b>94.10</b>

注: 加粗数据为最优值

(2) 模型组件。表 5 给出了分级模型不同组件的消融实验结果。由表 5 可知, 去掉 AFFB 的分级模型由于缺少自适应特征过滤, MFB 逐级挖掘细节特征的能力减弱, 分级效率降低; 去掉 FCFM 的模型输出仅由不同尺度的局部增强特征直接相加, 导致局部增强特征的互补信息缺失, 进而降低了模型的分级性能; 采用 CE 损失函数替代组合损失函数的模型, 由于 DR 样本分布不均衡以及细粒度特征不易识别的影响, 模型的分级性能同样有所下滑。

表 5 消融对比实验(%)  
Table 5 Ablation contrast experiment (%)

模型组件	Acc	Kappa	Sen	Spe
FCFM+Loss	73.67	76.54	85.51	80.41
AFFB+Loss	71.84	72.99	82.60	92.12
AFFB+ FCFM	78.86	86.52	90.35	92.34
Loss	69.86	74.32	84.98	90.63
AFFB+ FCFM+Loss	<b>80.58</b>	<b>88.70</b>	<b>94.20</b>	<b>94.10</b>

注: 加粗数据为最优值

综上, 本文算法所采用的 AFFB, FCFM 以及组合损失函数对提升视网膜病变分级性能有明显效果。

5 结束语

本文针对视网膜病变图像特征识别困难以及病变分级效率不高问题, 提出一种特征自适应过滤的视网膜病变分级算法。首先, 该算法采用逐级特征提取的方式对视网膜病变图像进行处理, 以获取视网膜图像不同尺度的局部特征信息。然后, 采用 AFFB 与 FCFM 增强视网膜病变图像的局部特征信息。最后, 使用组合损失函数对视网膜病变分级模型进行优化训练。实验结果表明, 该算法能有效定位视网膜病变图像的病变区域并提高分级效率。但由模型的预测结果可知, DR 后期的分级准确率还有较大提升的空间。

参考文献 (References)

[1] OGURTSOVA K, GUARIGUATA L, BARENGO N C, et al. IDF diabetes Atlas: global estimates of undiagnosed diabetes in adults for 2021[J]. Diabetes Research and Clinical Practice, 2022, 183: 109118.

[2] SHI L, ZHANG J X. Few-shot learning based on multi-stage transfer and class-balanced loss for diabetic retinopathy grading[EB/OL]. [2022-01-28]. <https://arxiv.org/abs/2109.11806>.

- [3] 谢云霞, 黄海于, 胡建斌. 基于深度卷积神经网络的糖尿病视网膜病变分期及病灶检测[J]. 计算机应用, 2020, 40(8): 2460-2464.  
XIE Y X, HUANG H Y, HU J B. Staging and lesion detection of diabetic retinopathy based on deep convolution neural network[J]. Journal of Computer Applications, 2020, 40(8): 2460-2464 (in Chinese).
- [4] 顾婷菲, 郝鹏翼, 白琮, 等. 结合多通道注意力的糖尿病性视网膜病变分级[J]. 中国图象图形学报, 2021, 26(7): 1726-1736.  
GU T F, HAO P Y, BAI C, et al. Grading of diabetic retinopathy combined with multi-channel attention [J]. Chinese Journal of Image Graphics, 2021, 26(7): 1726-1736 (in Chinese).
- [5] 张文轩, 吴秦. 基于多分支注意力增强的细粒度图像分类[J]. 计算机科学, 2022, 49(5): 105-112.  
ZHANG W X, WU Q. Fine-grained image classification based on multi-branch attention-augmentation[J]. Computer Science, 2022, 49(5): 105-112 (in Chinese).
- [6] DU R Y, CHANG D L, BHUNIA A K, et al. Fine-grained visual classification via progressive multi-granularity training of jigsaw patches[M]//Computer Vision - ECCV 2020. Cham: Springer International Publishing, 2020: 153-168.
- [7] CHANG D L, DING Y F, XIE J Y, et al. The devil is in the channels: mutual-channel loss for fine-grained image classification[J]. IEEE Transactions on Image Processing, 2020, 29: 4683-4695.
- [8] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//2017 IEEE International Conference on Computer Vision. New York: IEEE Press, 2017: 2999-3007.
- [9] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2016: 770-778.
- [10] SONG J W, YANG R Y. Feature boosting, suppression, and diversification for fine-grained visual classification[C]//2021 International Joint Conference on Neural Networks. New York: IEEE Press, 2021: 1-8.
- [11] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2018: 7132-7141.
- [12] PORWAL P, PACHADE S, KAMBLE R, et al. Indian diabetic retinopathy image dataset (IDRiD): a database for diabetic retinopathy screening research[J]. Data, 2018, 3(3): 25.
- [13] LUO L, XUE D Y, FENG X L. Automatic diabetic retinopathy grading via self-knowledge distillation[J]. Electronics, 2020, 9(9): 1337.
- [14] SIRAJUDEEN A, EZHILARASI M. Multi-scale LBP and SVM classification to identify diabetic retinopathy in lesions[J]. Current Medical Imaging Reviews, 2015, 11(1): 49-55.
- [15] QIAO L, ZHU Y, ZHOU H. Diabetic retinopathy detection using lesions[J]. Current Medical Imaging Reviews, 2015, 11(1): 49-55.
- [16] BHARDWAJ C, JAIN S, SOOD M. Transfer learning based robust automatic detection system for diabetic retinopathy grading[J]. Neural Computing and Applications, 2021, 33(20): 13999-14019.
- [17] WU Z, SHI G L, CHEN Y, et al. Coarse-to-fine classification for diabetic retinopathy grading using convolutional neural network[J]. Artificial Intelligence in Medicine, 2020, 108: 101936.
- [18] LIN T Y, ROYCHOWDHURY A, MAJI S. Bilinear CNN models for fine-grained visual recognition[C]//2015 IEEE International Conference on Computer Vision. New York: IEEE Press, 2015: 1449-1457.
- [19] YU C J, ZHAO X Y, ZHENG Q, et al. Hierarchical bilinear pooling for fine-grained visual recognition[M]//Computer Vision - ECCV 2018. Cham: Springer International Publishing, 2018: 595-610.
- [20] WANG Y M, MORARIU V I, DAVIS L S. Learning a discriminative filter bank within a CNN for fine-grained recognition[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE Press, 2018: 4148-4157.
- [21] PORWAL P, PACHADE S, KOKARE M, et al. IDRiD: diabetic retinopathy - segmentation and grading challenge[J]. Medical Image Analysis, 2020, 59: 101561.
- [22] ARAÚJO T, ARESTA G, MENDONÇA L, et al. DR/GRADUATE: uncertainty-aware deep learning-based diabetic retinopathy grading in eye fundus images[J]. Medical Image Analysis, 2020, 63: 101715.